Angewandte Statistik Bachelor of Science

Vergleich von Mittelwerten

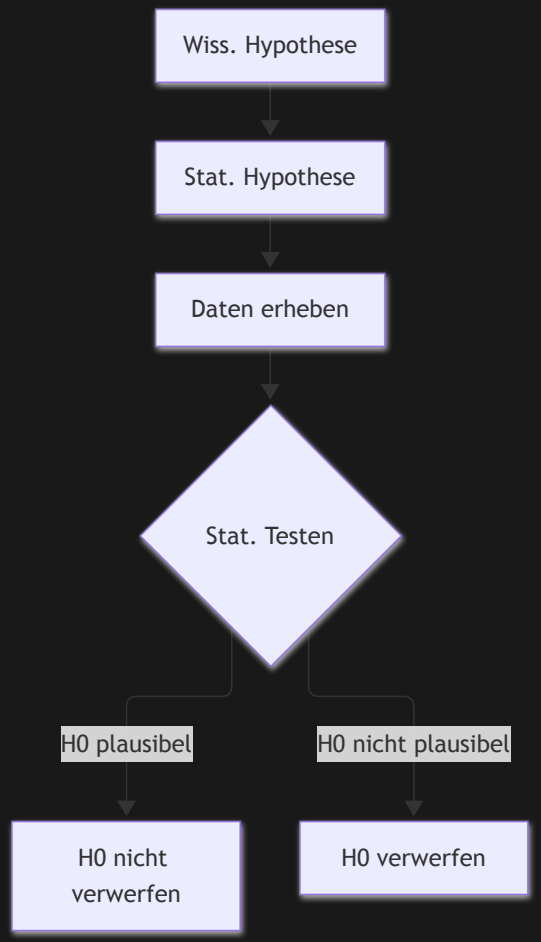
Patric Eichelberger
patric.eichelberger@bfh.ch
Bern University of Applied Sciences

29.10.2026

Inhalte

- Hypothesen
- Statistischer Test
- Signifikanz und p-Wert
- Entscheidungsfehler
- Vergleich Mittelwert einer Stichprobe mit Referenz
- Vergleich Mittelwerte von zwei Stichproben

Angewandte Fragestellung

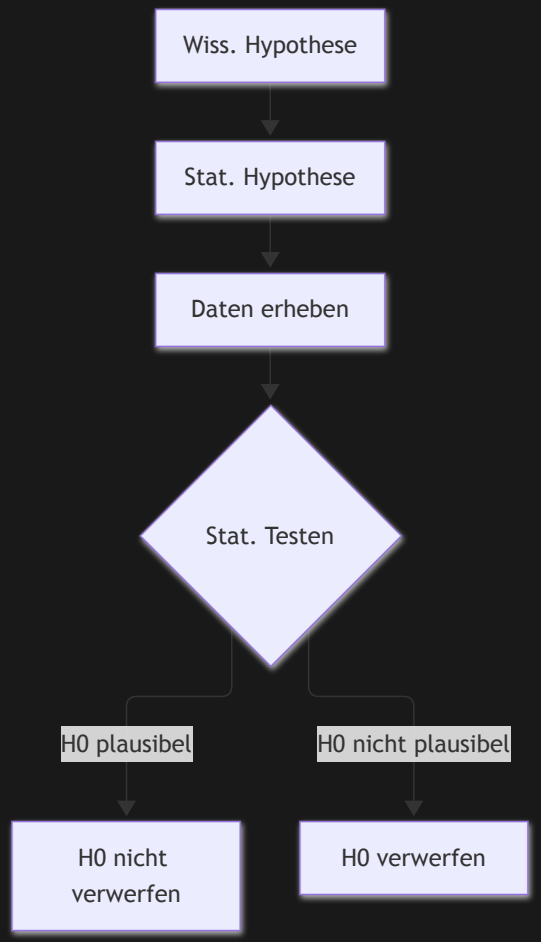


Frage: Unterscheidet sich die Körpergrösse zwischen Männern und Frauen?

Wissenschaftliche Hypothese: Die Körpergrösse von Männern und Frauen ist unterschiedlich.

> **Achtung**
>
> Es ist wissenschaftlich nicht redlich, zuerst die Daten zu erheben und erst dann die Hypothesen aufzustellen!

Präzisierung



Statistische Hypothese: Der Mittelwert der Körpergrösse von Männern und Frauen ist unterschiedlich.

$$\mu_w \neq \mu_m$$

Achtung

Wir schreiben nicht

$$\bar{x}_w = \bar{x}_m$$

da sich die Hypothese auf die Population und nicht die Stichprobe bezieht!

Statistische Hypothesen

Nullhypothese H_0

- Gegenteil der wissenschaftlichen Hypothese und Behauptung die man ablehnen möchte.
- Annahme: Unterschiede, die man in der Stichprobe beobachtet, sind lediglich durch Stichprobenvariation (zufällig) entstanden.

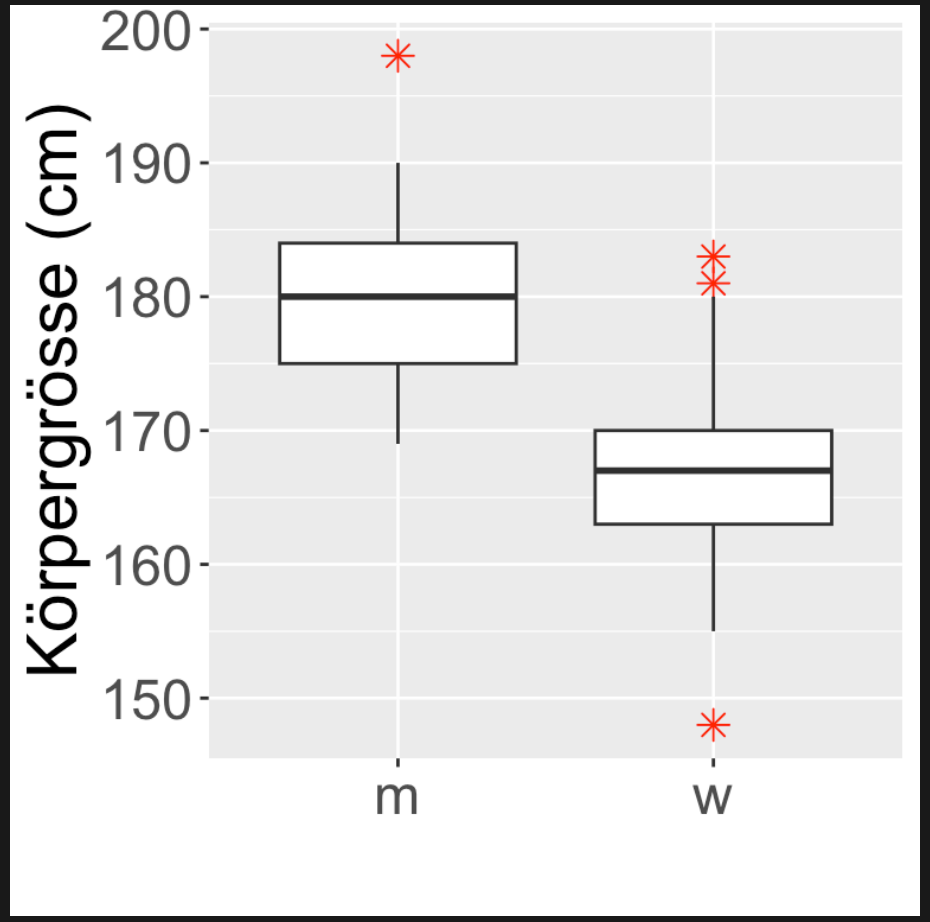
$$H_0 : \mu_w = \mu_m$$

Alternativhypothese H_A (oft auch H_1) - wissenschaftliche Hypothese

- Enthält in der Regel die Motivation eines Experimentes.

$$H_0 : \mu_w \neq \mu_m$$

Daten erheben



	m (N=45)	w (N=183)
Gewicht		
Mean (SD)	73.0 (9.34)	59.6 (6.67)
Median [Min, Max]	72.0 [53.0, 105]	60.0 [47.0, 85.0]

Prinzip

Wir nehmen an, die Nullhypothese stimmt (es gibt keinen Unterschied):

> Wie gross ist dann die Wahrscheinlichkeit, eine so grosse Differenz (oder noch grössere) zu erhalten wie in unserer Stichprobe?

Oder anders: Wie *extrem* sind unsere Daten unter der Annahme, dass die Nullhypothese stimmt?

Teststatistik

Um den statistischen Test durchzuführen, muss zunächst die sogenannte **Teststatistik** aus den Daten berechnet werden.

$$\text{Teststatistik} = \frac{\text{Durch Modell erklärte Varianz}}{\text{Durch Modell nicht erklärte Varianz}} = \frac{\text{Effekt}}{\text{Fehler}}$$

Im Falle des t-Tests zum Vergleich von Mittelwerten

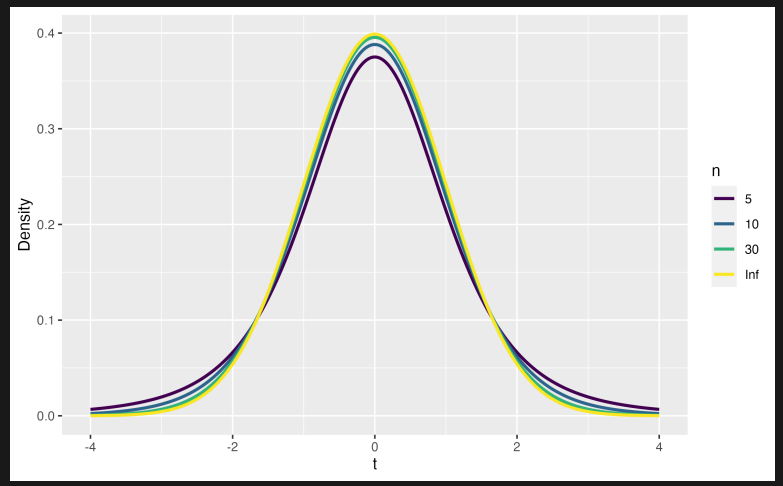
$$t = \frac{\text{Differenz zw. Gruppenmittelwerten}}{\text{Standardfehler}}$$

Merke

t wird grösser falls:

- Die Differenz, d.h. der Effekt, grösser wird.
- Der Standardfehler kleiner wird: Stichprobenstreuung wird kleiner und/oder der Stichprobenumfang wird grösser.

Exkurs: t-Verteilung und t-Wert



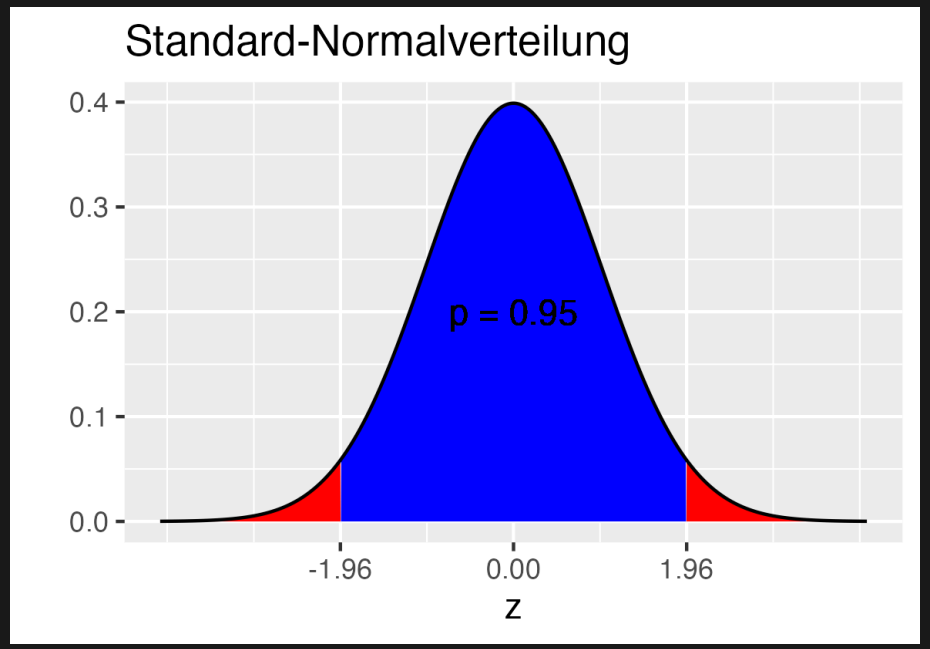
- Beim Schätzen von Mittelwerten in normalverteilten Populationen.
- Wenn Stichproben klein sind.
- Wenn die Populations-Standardabweichung nicht bekannt ist.

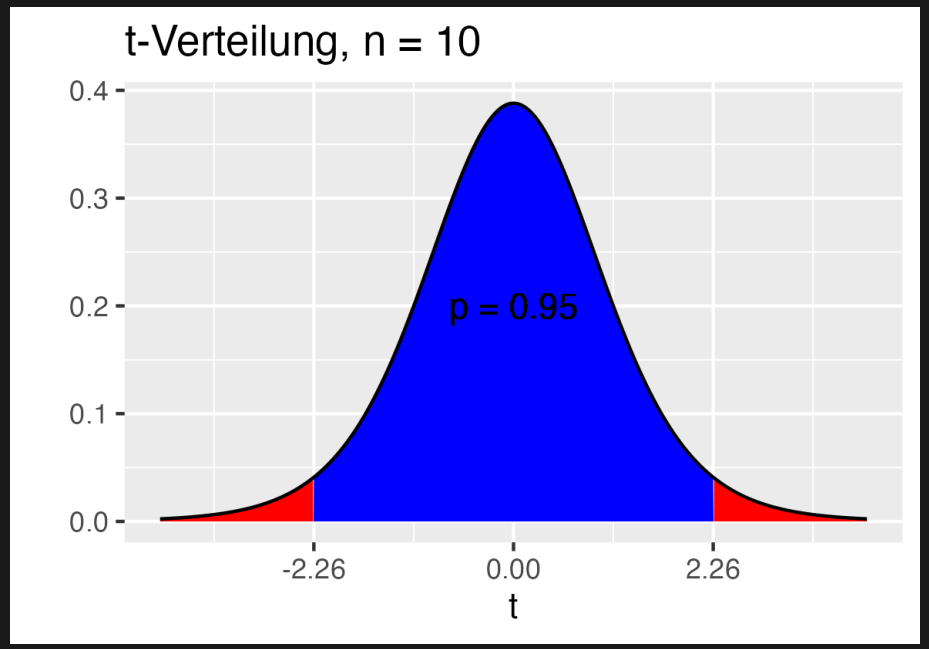
$$t = \frac{\text{Differenz zw. Gruppenmittelwerten}}{\text{Standardfehler}} = \frac{d}{SE} = \frac{d}{\frac{SD}{\sqrt{n}}}$$

Merke

Wenn t-Verteilung vorliegt müssen auf der x-Achse andere Werte gewählt werden als bei Normalverteilung um die 95%-Fläche zu berechnen.

Exkurs: t-Verteilung und t-Wert (cont.)



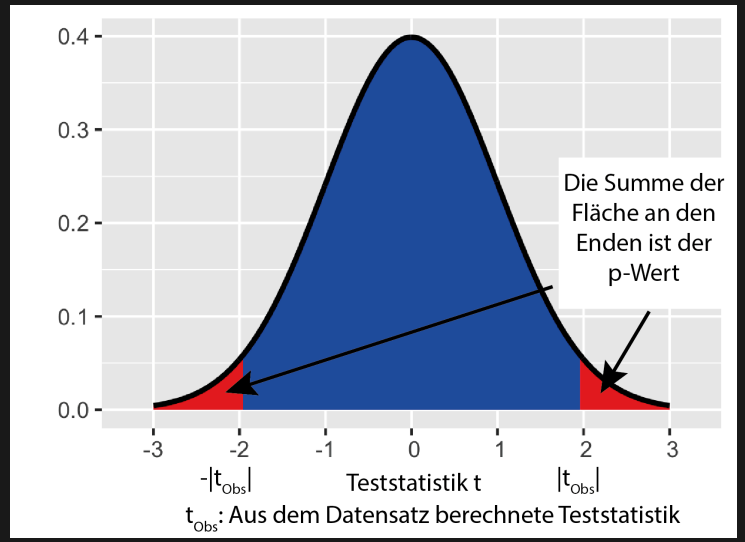


$$CI = \bar{x} \pm 1.96 \cdot SE$$

$$CI = \bar{x} \pm 2.26 \cdot SE$$

p-Wert

- *p-Wert*: die Wahrscheinlichkeit, dass der beobachtete Wert der Teststatistik oder noch extremer unter der Nullhypothese vorkommen kann.
- Ist diese Wahrscheinlichkeit genügend klein, so ist die Nullhypothese nicht plausibel.
- Übliche Grenze (Signifikanzniveau) 5%.

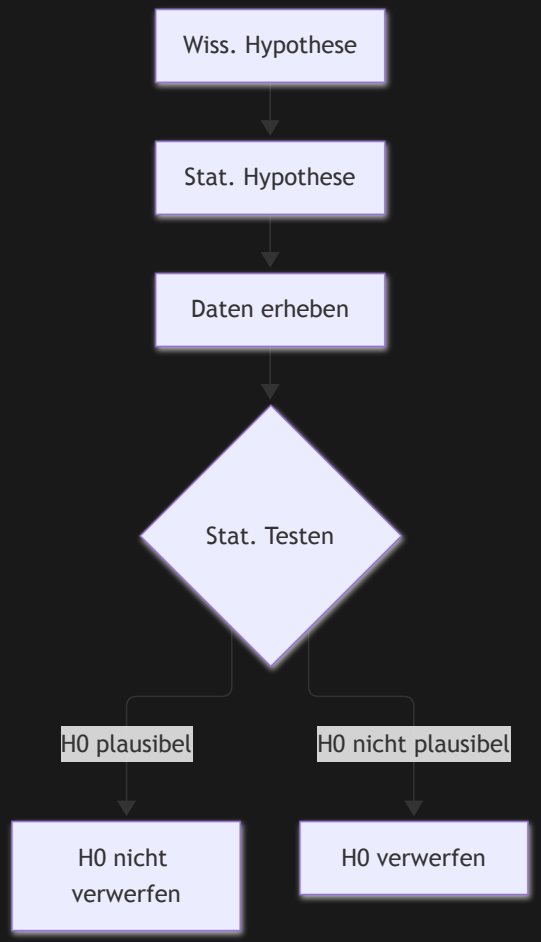


$$t_{\text{Obs}} = \frac{d}{SE}$$

Merke

Die Nullhypothese wird abgelehnt wenn der beobachtete t-Wert t_{Obs} den dem Signifikanzniveau zugehörigen kritischen t-Wert t_{Crit} überschreitet.

Entscheid



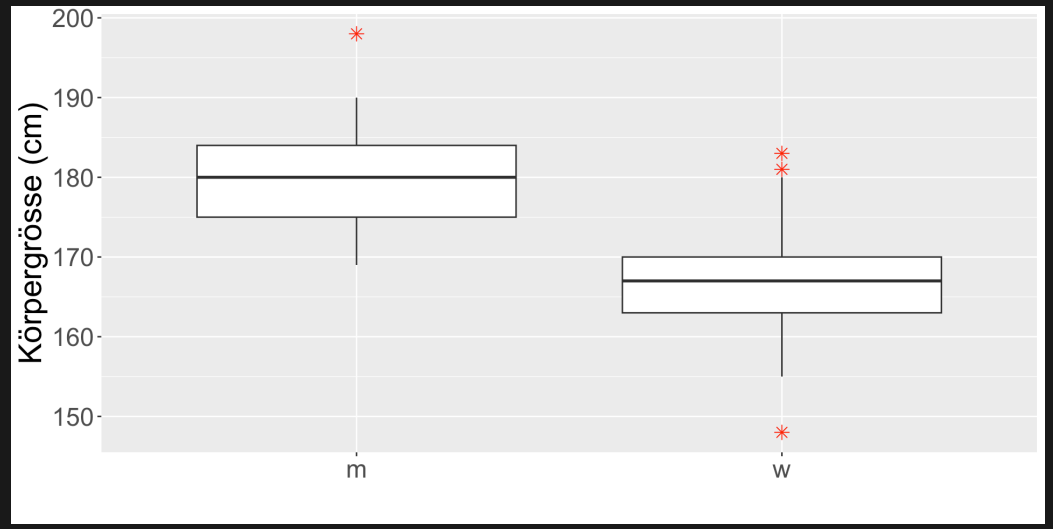
p-Wert kleiner als Signifikanzniveau: H_0 verwerfen

- Also $|t_{\text{Obs}}| > |t_{\text{Crit}}|$
- Signifikante Abweichungen von der Nullhypothese => man geht davon aus, dass H_A gilt.

p-Wert nicht kleiner als Signifikanzniveau: H_0 nicht verwerfen

- Die Nullhypothese ist plausibel und wird beibehalten.
- Dies berechtigt aber nicht zur Behauptung, dass H_A falsch ist!

Beispiel Körpergrösse



t	p	Differenz	CIlower	CIupper
11.07	<0.001	13.39	11.01	15.78

- Die Wahrscheinlichkeit, eine Teststatistik so gross wie t oder noch extremer zu erhalten ist kleiner als 0.1%, falls die Nullhypothese wahr ist
- Falls die Nullhypothese wahr ist, dann würde die Stichprobenvariation in 100 identischen Studien lediglich <0.1% eine Teststatistik ergeben, die mindestens so weit weg vom Nullwert ist wie t.

p-Wert: Fehlinterpretation

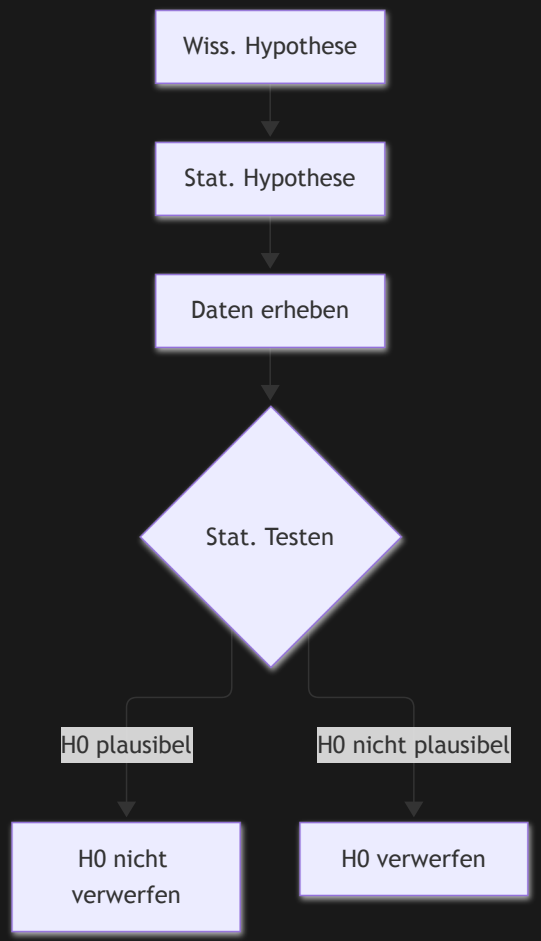
Der p-Wert ist **nicht**

- die Wahrscheinlichkeit, dass die Nullhypothese stimmt
- die Wahrscheinlichkeit, dass die Alternativhypothese falsch ist
- die Wahrscheinlichkeit, dass das Ergebnis nur durch Zufall entstanden ist
- eine Quantifizierung der (klinischen) Relevanz der Ergebnisse
- eine Abschätzugn dafür, wie verlässlich die Ergebnisse sind

Der p-Wert ist keine Interpretation, er braucht Interpretation.

- M. Baker, “Statisticians issue warning over misuse of p values,” vol. 531, pp. 151–151, 2016.
- https://www.horizonte-magazin.ch/2019/03/07/braucht-es-den-statistischen-schwellenwert-noch/
- https://www.nzz.ch/karriere/studentenleben/der-problem-wert-ld.133818

Entscheid und Irrtum



Entscheid	**H0 wahr - nicht unterschiedlich**	**H1 wahr - unterschiedlich**
Nicht unterschiedlich	Korrekter Entscheid Häufigkeit $1 - \alpha$ True Negative Spezifität	Inkorrekter Entscheid Häufigkeit β False Negative Typ 2 Fehler
Unterschiedlich	Inkorrekter Entscheid Häufigkeit α False Positive Typ 1 Fehler	Korrekter Entscheid Häufigkeit $1 - \beta$ True Positive Sensitivity (Power)

Power: Stichprobenumfang, Streuung und Differenzen

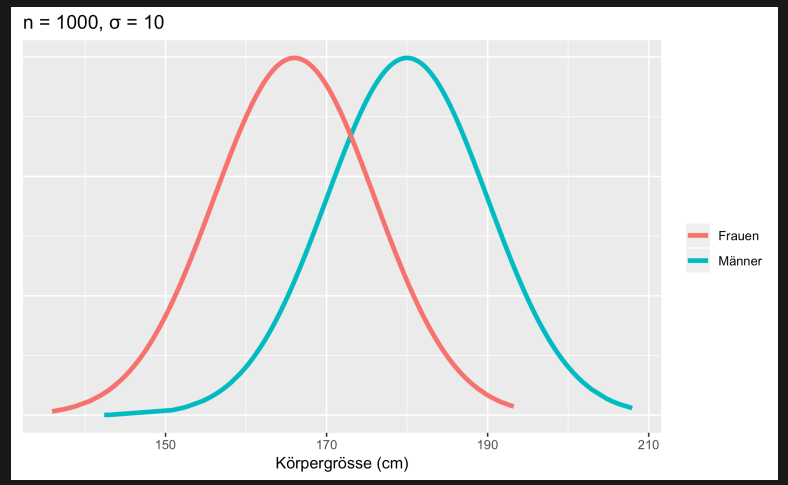
Die Power, Macht oder Güte eines Tests, ist die Wahrscheinlichkeit, bei wahrer Alternativhypothese die Nullhypothese zu verwerfen, und ist:

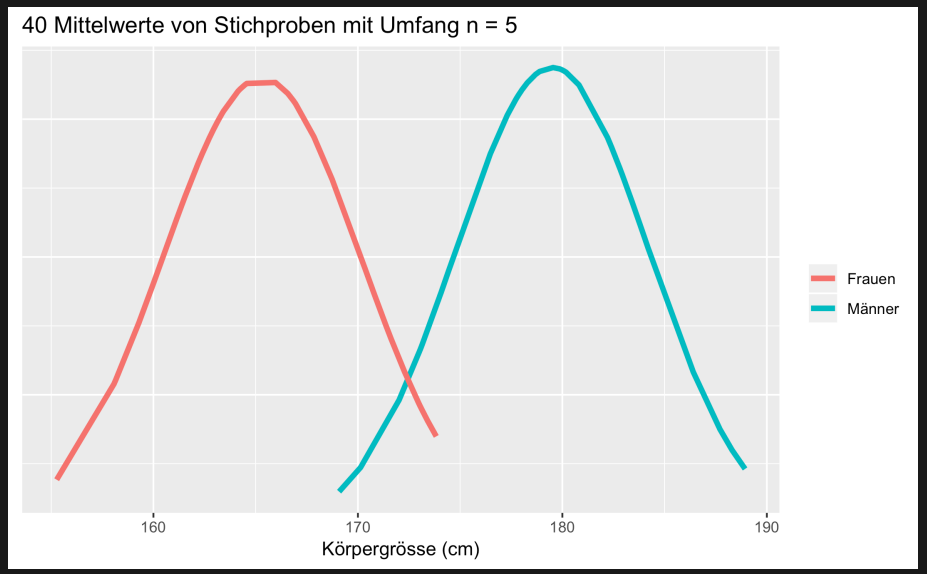
$$\gamma = 1 - \beta$$

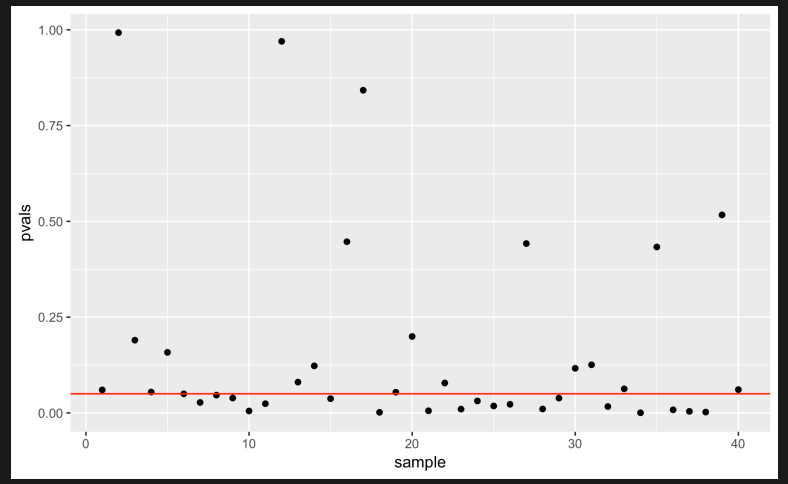
Merke

- Power wird grösser wenn…
  - Die Stichproben grösser sind.
  - Die Streuungen der Stichproben kleiner sind.
  - Die Differenz zwischen den Stichproben grösser ist.

Beispiel Fehler 2. Art n = 5

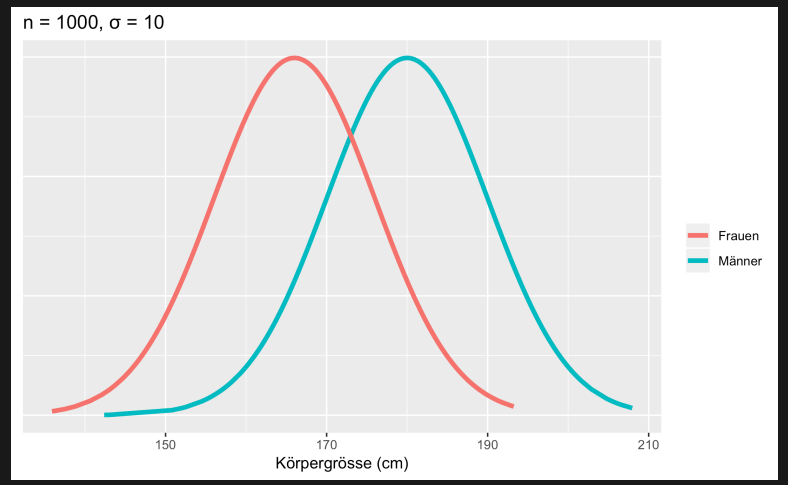


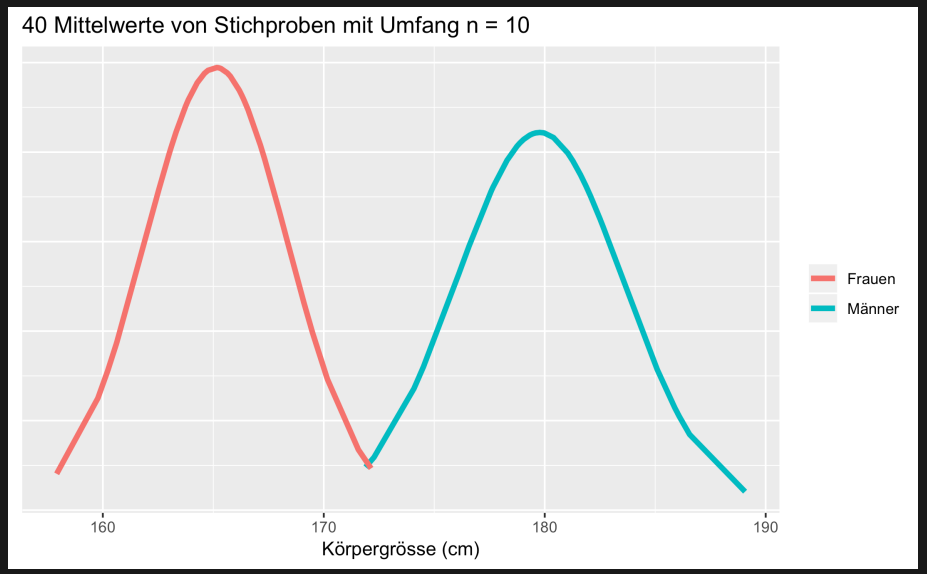


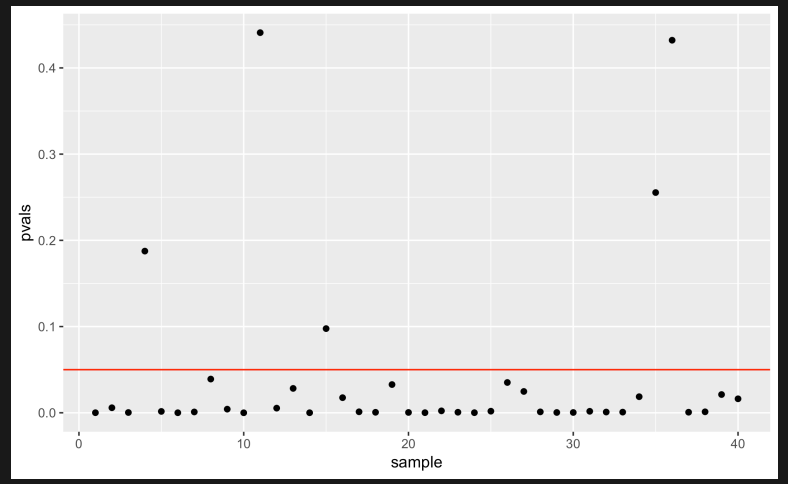


- Theoretische Power: 0.495
- True (+): 19 / False (-): 21
- $(1-\beta) = \frac{19}{40} = 0.475$

Beispiel Fehler 2. Art n = 10

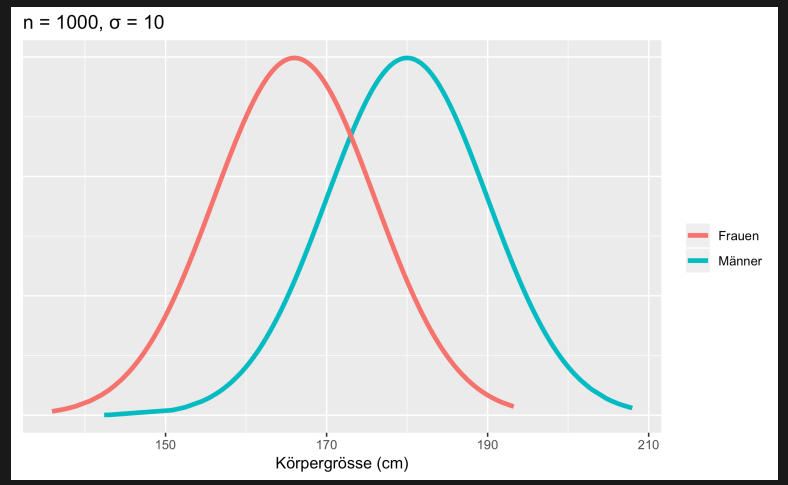


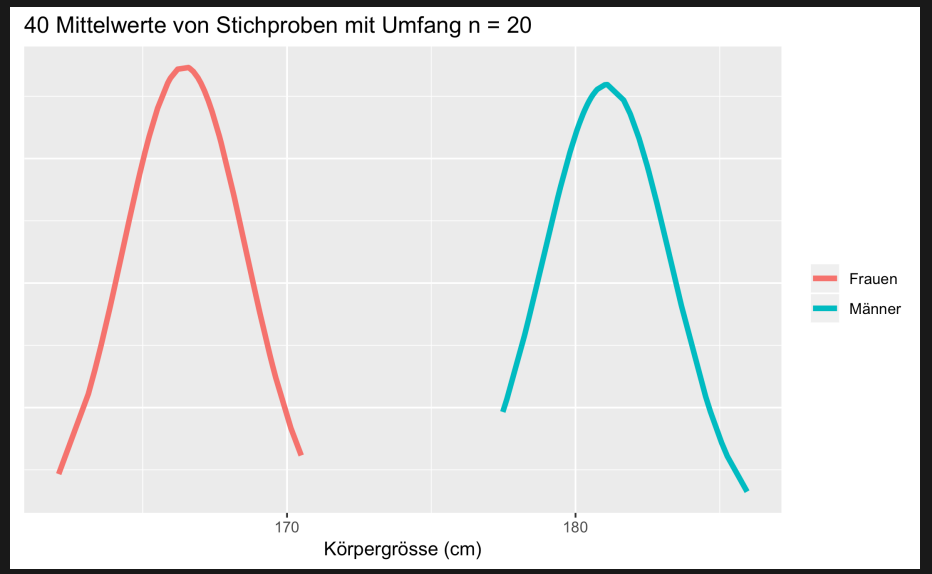


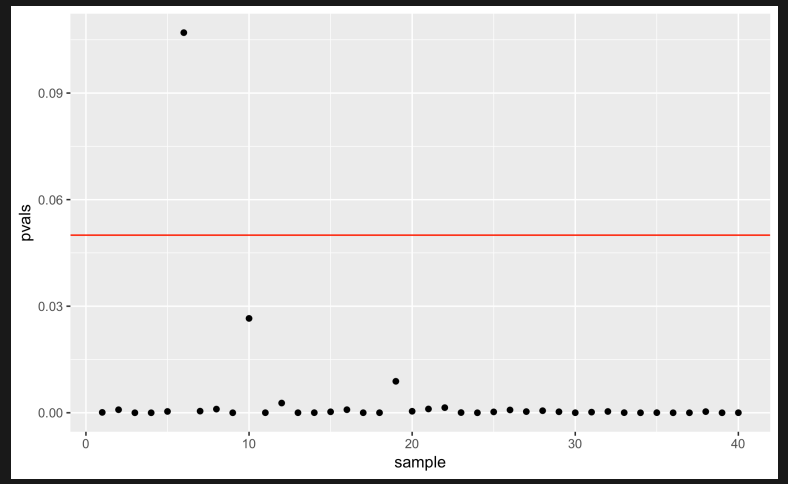


- Theoretische Power: 0.841
- True (+): 35 / False (-): 5
- $(1-\beta) = \frac{35}{40} = 0.875$

Beispiel Fehler 2. Art n = 20

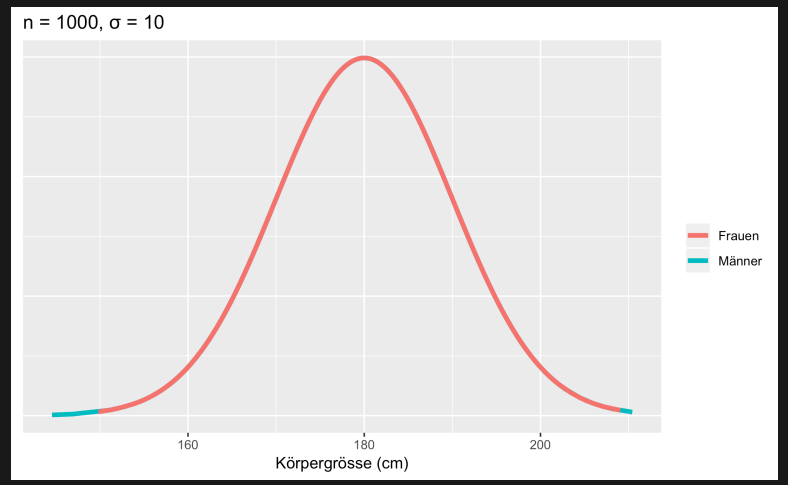


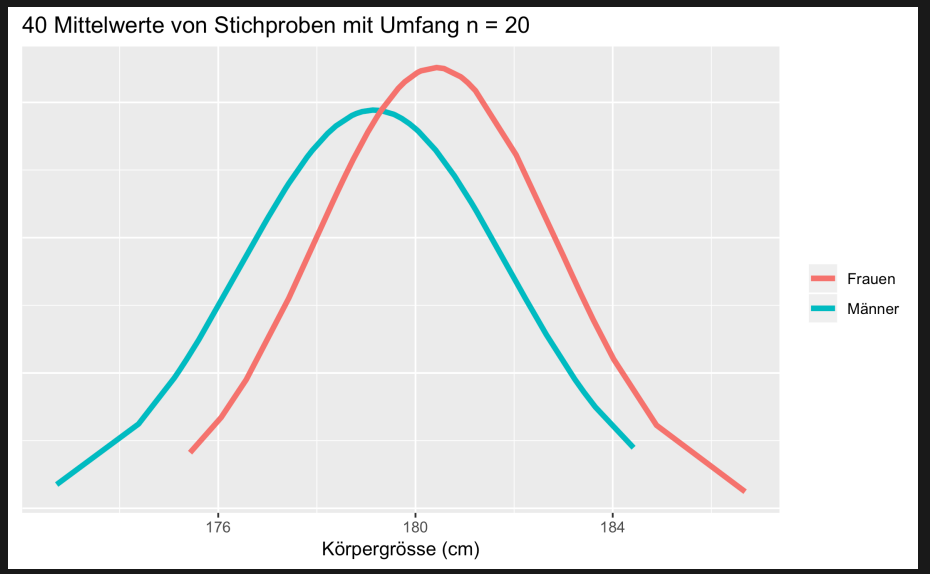


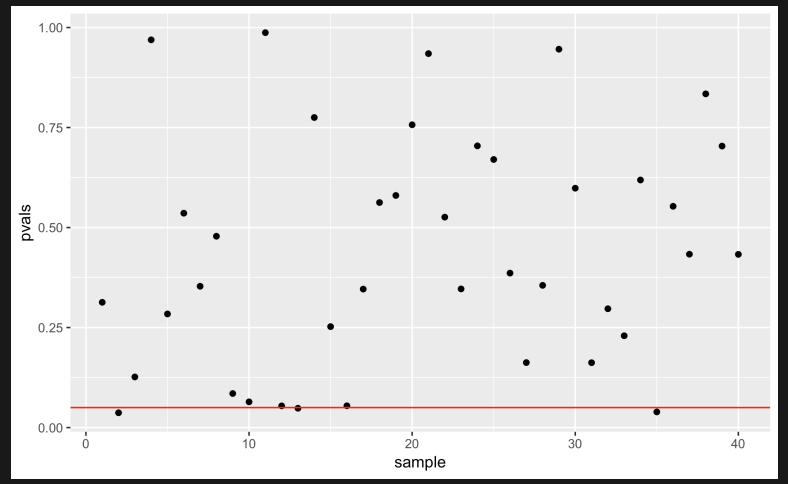


- Signifikanzniveau $\alpha = 0.05$
- True (-): 38 / False (+): 2
- $\alpha = \frac{2}{40} = 0.05$

Beispiel Fehler 1. Art

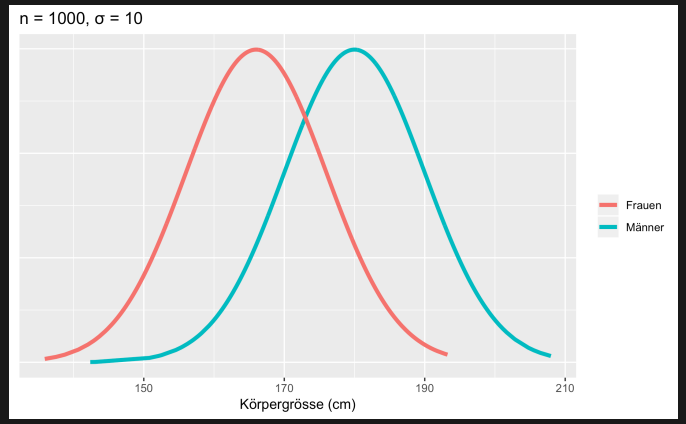






- Signifikanzniveau $\alpha = 0.05$
- True (-): 38 / False (+): 2
- $\alpha = \frac{2}{40} = 0.05$

Bestimmen des Stichprobenumfangs



Effektstärke (Cohen's d)

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s}$$

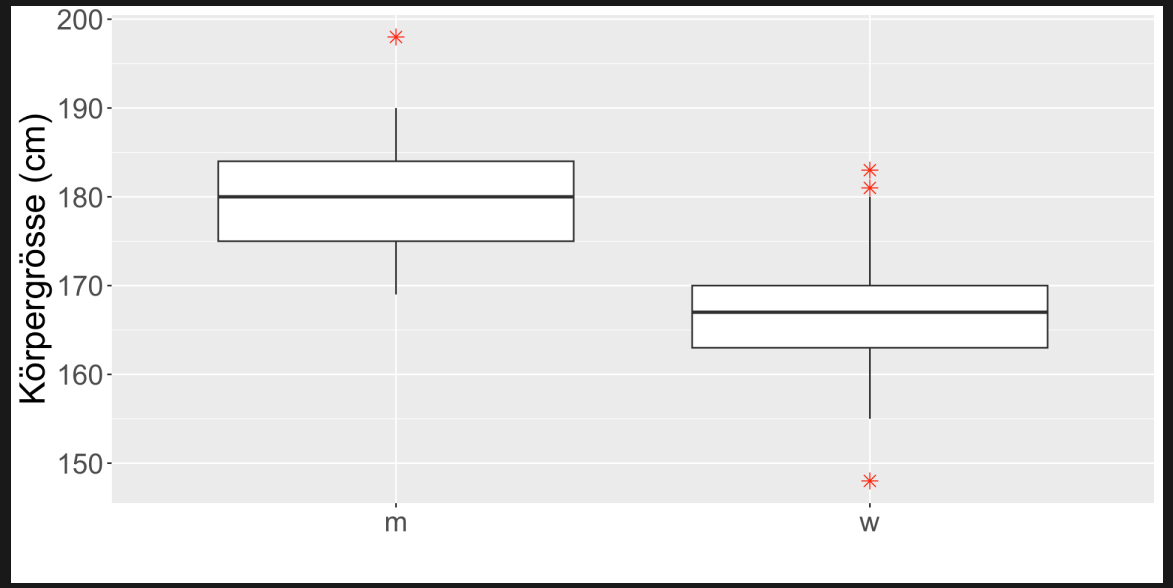
- Klein: 0.2 bis 0.3
- Mittel: 0.5 bis 0.8
- Stark: $>$ 0.8

- Festlegen von…
  - Signifikanzniveau
  - Power. Üblich sind 0.8 oder 0.9.
  - Effektstärke. Oft 0.5.
- Berechnen der Stichprobengrösse um den Effekt mit der gewünschten Power bei gegebenem Signifikanzniveau nachzuweisen.

Effektstärke für Beispiel

$$d = \frac{180 - 166}{10} = 1.4$$

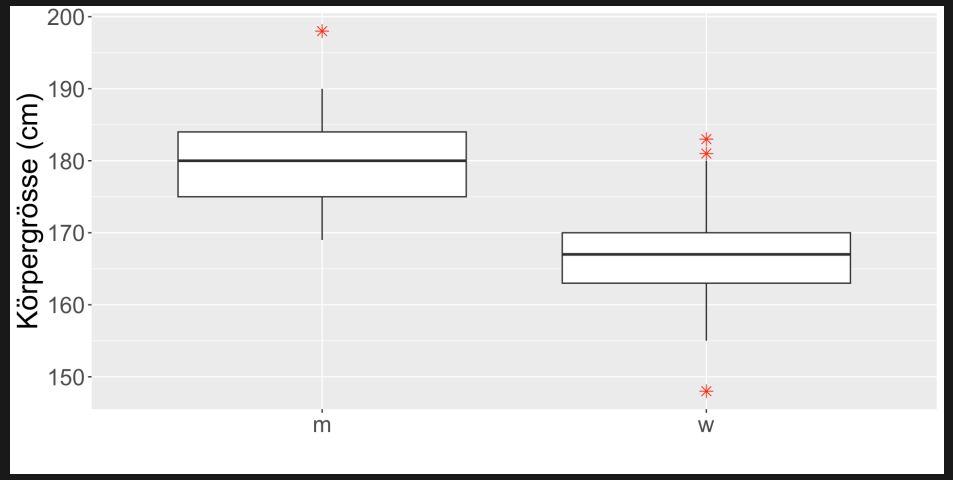
Beispiel Körpergrösse Entscheid



t	p	Differenz	CIlower	CIupper
11.07	<0.001	13.39	11.01	15.78

- Da $p < 0.05$ ist, verwerfen wir die Nullhypothese, dass es auf dem Signifikanzniveau von 5% keinen Unterschied der Körpergrösse zwischen Männern und Frauen gibt.
- Wir könnten einen Fehler 1. Art begehen und fälschlicherweise zum Schluss kommen, dass sich die Körpergrösse zwischen Männern und Frauen unterscheidet.

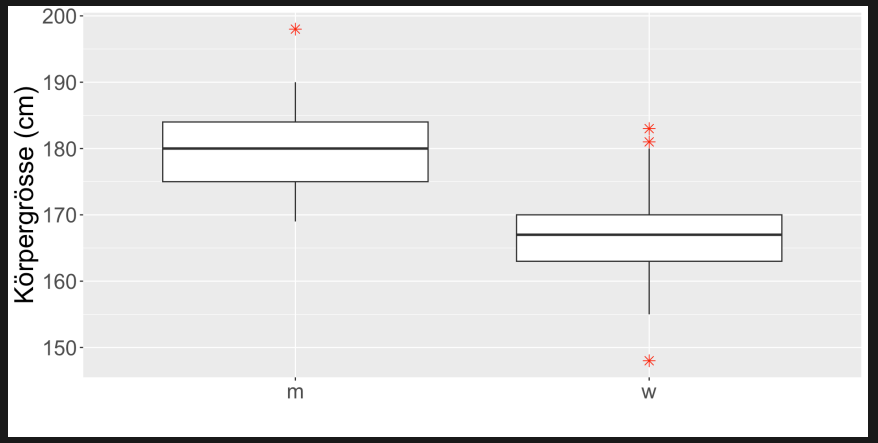
Konfidenzintervall



t	p	Differenz	CIlower	CIupper
11.07	<0.001	13.39	11.01	15.78

- Konfidenzintervalle: Bereich plausibler Werte für einen Populationsparameter
- Im Beispiel für die mittlere Differenz der Körpergrösse zwischen Männern und Frauen
- Null ist nicht im Vertrauensintervall drin: eine Differenz von Null ist nicht plausibel: H_0 wird verworfen.
- Selber Schluss wie mit dem p-Wert, aber mit wertvoller Zusatzinformation

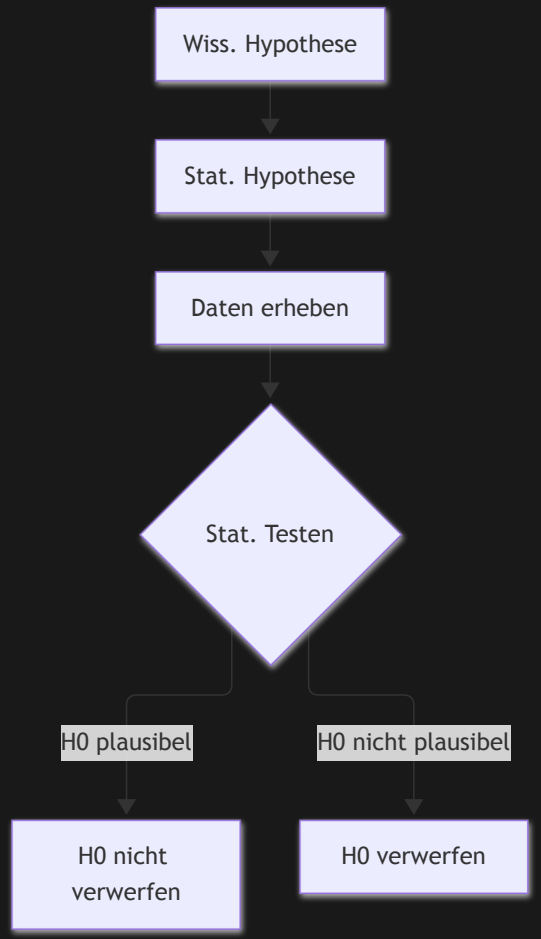
Konfidenzintervall (cont.)



t	p	Differenz	CIlower	CIupper
11.07	<0.001	13.39	11.01	15.78

- Der Unterschied der Körpergrösse zwischen Frauen und Männern beträgt mit 95% Vertrauenswahrscheinlichkeit zwischen 11.01 cm und 15.78 cm.
- Wir bekommen aus dem Vertrauensintervall Informationen zur Richtung und der Grösse des Effekts.
- Dies lässt die Interpretation zu, ob ein signifikanter Unterschied auch klinisch relevant ist.

Fehlinterpretationen Hypothesentests



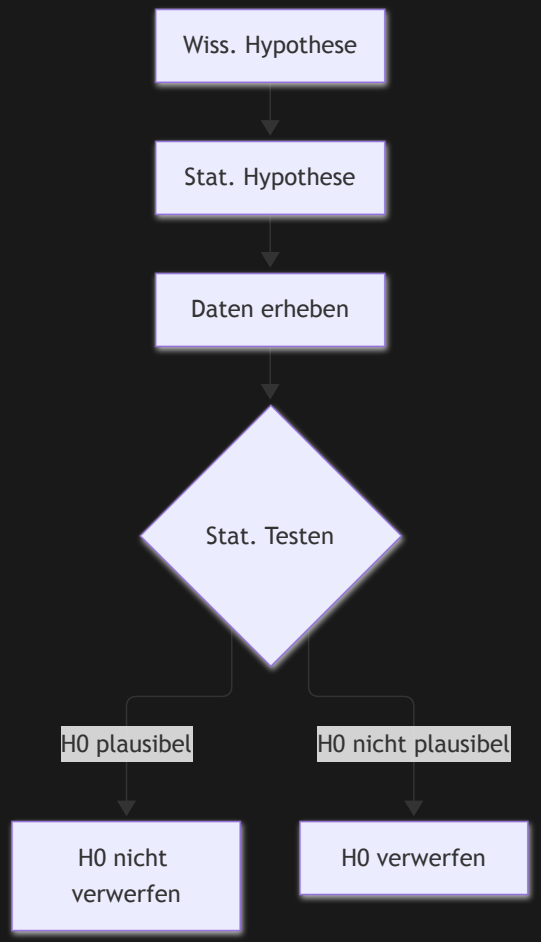
- Hypothesentests kommen zu einem binären Entscheid, der entweder wahr oder falsch sein kann.
- Ablehnung der Nullhypothese heisst nicht, dass die Alternativhypothese wahr ist (kein Beweisen!)
- Nicht-Ablehnung der Nullhypothese heisst nicht, dass diese wahr ist.
- Hypothesen können nur widerlegt, aber nicht bewiesen werden (Prinzip der Falsifikation)
- Hypothesen müssen sich bewähren und sind so lange Gültig, bis Evidenz **dagegen** gefunden wird.

- Karl Popper 1959 *Logik der Forschung*

Wann welchen Test?



Zusammenfassung



- Wir haben gesehen wie ein statistischer Test abläuft.
- Mit dem p-Wert quantifizieren wir Evidenz gegen die Nullhypothese.
- Aussagekräftiger als p-Werte und Signifikanz sind Konfidenzintervalle.
- Hypothesentests haben nach wie vor eine grosse Bedeutung in der wissenschaftlichen Literatur.
- Darum muss man das Prinzip und die Begriffe des statistischen Testens verstehen.